



Université du Québec  
à Chicoutimi

Jalon 3

8INF970 - Atelier pratique en cybersécurité II

Fehmi Jaafar      Samuel Desbiens

Justin Bossard

Mattéo Gouhier

Paul Mathé

Samuel Plet

Léo Raclet

7 avril 2026

# Table des matières

|          |                                                                  |           |
|----------|------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                              | <b>2</b>  |
| <b>2</b> | <b>Évolution vers une Architecture Hybride (RAG &amp; LLM)</b>   | <b>3</b>  |
| 2.1      | Changement de Paradigme : De RoBERTa à Llama 3 . . . . .         | 3         |
| 2.2      | Abandon du Fine-Tuning au profit du Prompt Engineering . . . . . | 3         |
| 2.3      | Le Système de Mémoire : Architecture RAG . . . . .               | 4         |
| 2.3.1    | Scraping RSS . . . . .                                           | 4         |
| 2.3.2    | Vectorisation et Stockage (ChromaDB) . . . . .                   | 4         |
| 2.3.3    | Prompt Enrichi . . . . .                                         | 5         |
| 2.4      | Explication du choix des données . . . . .                       | 5         |
| 2.5      | Nouveau Format de Sortie (Standard JSON v2) . . . . .            | 5         |
| 2.6      | Flux final . . . . .                                             | 5         |
| 2.6.1    | Entrée . . . . .                                                 | 5         |
| 2.6.2    | Récupération . . . . .                                           | 6         |
| 2.6.3    | Travail du LLM . . . . .                                         | 6         |
| 2.6.4    | Sortie . . . . .                                                 | 6         |
| 2.7      | Sécurité et Robustesse Technique . . . . .                       | 6         |
| <b>3</b> | <b>Analyses des résultats et des performances</b>                | <b>7</b>  |
| <b>4</b> | <b>Marketing</b>                                                 | <b>8</b>  |
| 4.1      | Introduction . . . . .                                           | 8         |
| 4.2      | Analyse Persona des utilisateurs cibles . . . . .                | 8         |
| 4.3      | Synthèse des personas . . . . .                                  | 9         |
| 4.4      | Différenciation par rapport à la concurrence . . . . .           | 9         |
| 4.5      | Page web de l'application . . . . .                              | 10        |
| 4.6      | Présence sur les plateformes sociales . . . . .                  | 11        |
| 4.7      | Stratégie de collaborations et de publicités . . . . .           | 12        |
| <b>5</b> | <b>Conclusion</b>                                                | <b>14</b> |
|          | <b>Références</b>                                                | <b>15</b> |

# Partie 1

## Introduction

L'objectif de ce troisième jalon est de transformer le prototype initial de VerifAI en un produit commercial viable. Alors que les itérations précédentes se concentraient sur une classification binaire simple, cette étape marque une évolution significative vers une architecture hybride de Génération Augmentée par Récupération (RAG). Cette approche permet non seulement d'évaluer la véracité d'un contenu, mais également de fournir une justification détaillée et sourcée à l'utilisateur.

Le présent rapport documente :

- L'amélioration de l'intelligence artificielle par le passage au modèle Llama 3 et l'intégration d'une base de données vectorielle ChromaDB, alimentée par des sources de presse officielles.
- L'analyse des résultats et des performances du produit.
- L'analyse de la stratégie marketing, incluant l'étude des personas cibles et le positionnement concurrentiel du produit.
- L'évaluation technique des résultats obtenus avec cette nouvelle architecture.

## Partie 2

# Évolution vers une Architecture Hybride (RAG & LLM)

Pour dépasser les limites d’une simple classification “Vrai/Faux”, l’architecture a évolué vers un système de **Génération Augmentée par Récupération (RAG)**. Cette approche permet non seulement de détecter la désinformation, mais aussi de fournir une justification sourcée en se basant sur des faits réels et actualisés.

### 2.1 Changement de Paradigme : De RoBERTa à Llama 3

Initialement basé sur RoBERTa pour la classification, le système utilise désormais **Llama 3**. Ce changement est motivé par deux besoins :

- **Le Raisonnement** : Capacité à expliquer *pourquoi* une information est jugée suspecte. RoBERTa ne donnait qu’une réponse Vrai/Faux, mais Llama, en tant que LLM, permet de justifier le choix.
- **Le Contexte** : Capacité à comprendre le contexte global de l’article, et pas seulement une phrase isolée.

### 2.2 Abandon du Fine-Tuning au profit du Prompt Engineering

La stratégie initiale envisageait un fine-tuning supervisé (SFT) sur un jeu de données spécifique. Cette approche a été écartée au profit du *Prompt Engineering* couplé à l’architecture RAG, en raison de plusieurs contraintes techniques et méthodologiques.

---

Bien que non retenu pour l’itération actuelle, le fine-tuning supervisé présente des avantages documentés. En termes de performance et de précision, comme le démontrent Shin et al. (2025), les modèles fine-tunés peuvent surpasser significativement les approches de prompt engineering (jusqu’à 28 points sur certains benchmarks), offrant une stabilité supérieure pour des tâches hautement spécialisées. De plus, l’entraînement permet de contraindre le modèle à générer systématiquement une structure JSON exacte, limitant ainsi les erreurs de syntaxe. Cette méthode optimise également l’inférence en internalisant les règles de formatage, ce qui réduit le nombre de tokens nécessaires en entrée et diminue le temps d’apparition du premier mot (*Time To First Token*). Enfin, les méthodes PEFT (comme LoRA) permettent d’obtenir des performances élevées sur des modèles de taille modeste tout en réduisant les coûts de calcul, offrant un compromis optimal entre précision et ressources (Vangibhurathachhi 2025).

Cependant, la mise en œuvre de cette méthode s’est heurtée à la difficulté de constituer un ensemble de données adéquat. Trois sources principales avaient été identifiées initialement : Webz.io (un répertoire de contenus thématiques), ISOT (un jeu de données binaire d’articles réels et factices) et FakeNewsNet

(un dépôt de données vérifiées de PolitiFact et GossipCop). Pour générer un dataset performant, il est impératif de coupler chaque article à son verdict et à une justification textuelle précise. Or, ces bases manquent de la justification native nécessaire. L’exploitation de Webz.io a été écartée en raison d’un volume brut excédant les ressources matérielles et de l’absence de verdicts validés par des experts. FakeNewsNet, malgré ses labels clairs, souffre quant à lui d’une absence totale de justifications textuelles.

Puisque le fine-tuning exige des ressources importantes et des données volumineuses de haute qualité, l’absence de justifications natives aurait rendu nécessaire l’usage de données synthétiques. Cette alternative introduit des risques critiques de biais. D’une part, la généralisation abusive via des justifications stéréotypées peut limiter le modèle à reproduire des patrons de phrases au lieu d’analyser le texte. D’autre part, forcer la génération de justifications complexes sans lien direct avec les faits réels crée une incohérence sémantique qui augmente drastiquement le risque d’introduire des hallucinations dans le dataset. Par ailleurs, l’usage d’un dataset restreint forcerait une mémorisation d’exemples spécifiques (surapprentissage ou *overfitting*) au détriment de la logique de détection universelle.

---

Outre la problématique des données, le recours au fine-tuning s’est avéré être une démarche superflue face aux capacités des modèles récents. Le système repose désormais sur Llama 3 (version Instruct), un modèle nativement optimisé pour suivre des directives complexes et produire des formats de sortie stricts comme le JSON. Réentraîner les poids d’un modèle de plusieurs milliards de paramètres uniquement pour lui imposer une structure de réponse représente un effort disproportionné par rapport aux gains attendus.

Par conséquent, le passage au *Prompt Engineering* et au RAG a été privilégié pour la flexibilité accrue qu’il offre. Comme le soulignent Kermani et al. (2025), le prompt engineering et le RAG permettent une adaptation rapide et un déploiement plus flexible, particulièrement adaptés aux scénarios nécessitant une généralisation. Cette approche facilite également la gestion des ressources ; Pornprasit et Tantithamthavorn (2024) recommandent l’approche *few-shot* lorsque les données sont insuffisantes pour un fine-tuning complet, permettant une performance modérée avec une consommation de ressources réduite. De plus, elle assure une séparation claire des préoccupations en intégrant des informations externes actuelles via une base vectorielle (ChromaDB). Comme le confirment Ovadia et al. (2024), l’injection de connaissances par récupération (RAG) est plus adaptée que le fine-tuning pour gérer des données dynamiques, laissant ainsi le modèle se concentrer sur l’analyse logique. Enfin, la maintenance est grandement simplifiée, car l’ajustement des prompts en temps réel évite les cycles d’entraînement chronophages et la lourde gestion de fichiers de modèles.

## 2.3 Le Système de Mémoire : Architecture RAG

L’innovation majeure réside dans l’ajout d’une “mémoire factuelle” qui permet à l’IA de consulter des sources de confiance avant de répondre.

### 2.3.1 Scraping RSS

Le système n’est plus statique. Un module de collecte automatisé (`scripts/fetch_news.py`) s’exécute tout les jours pour parcourir les flux **RSS** de sources de presse reconnues (Le Monde et France 24). Grâce aux bibliothèques **Feedparser** et **Newspaper3k**, le contenu textuel est extrait, nettoyé de ses balises HTML, et centralisé dans un dataset de référence.

### 2.3.2 Vectorisation et Stockage (ChromaDB)

Pour que l’IA puisse “chercher” dans ces milliers d’articles, nous utilisons :

- **Sentence-Transformers (all-MiniLM-L6-v2)** : Ce modèle transforme chaque article de presse en un vecteur mathématique de 384 dimensions représentant son sens sémantique.

- **ChromaDB** : Une base de données vectorielle haute performance qui stocke ces vecteurs. Elle permet de trouver rapidement les articles les plus proches sémantiquement de la requête de l'utilisateur.

### 2.3.3 Prompt Enrichi

Maintenant, avant chaque requête, on récupère l'article de notre base le plus proche sémantiquement du texte à analyser, ainsi qu'un score de similitude. Si ce score dépasse le seuil mis en place, l'article est envoyé comme source dans la requête à notre LLM, pour qu'il rende son verdict avec les informations actuelles. Dans le cas contraire, seulement l'information dont on demande une vérification est envoyé dans le prompt, pour éviter que le LLM se base sur un article qui n'a pas de rapport, et donc répondre que comme les articles sont sur des sujets différents, l'informations est fausse.

## 2.4 Explication du choix des données

Le succès d'un système RAG repose sur la fiabilité des sources. En choisissant France 24 et Le Monde, on ne prendra pas seulement des flux de données d'informations, mais on s'assure de la qualité des vérifications. Ces deux rédactions sont reconnues pour avoir des informations sourcées et recoupées, ce qui est indispensable pour servir de base pour notre projet.

L'intérêt majeur réside dans leur complémentarité. D'un côté, France 24 produit des articles en continu sur les sujets d'actualités, donc cela nous assure une réactivité immédiate sur les événements mondiaux. De l'autre, Le Monde apporte, avec des articles moins nombreux mais plus développés, nous donne une profondeur d'analyse et une rigueur plus grande. Ce binôme permet au modèle de disposer d'une base de connaissances équilibrée, capable de traiter aussi bien une informations extrêmement récente, comme aller chercher les détails précis d'une autre information.

Enfin, il y a un enjeu linguistique et technique. Ces sources produisent des textes très bien écrit, cela nous semble pouvoir aider à réduire des biais sensationnalistes. Pour notre modèle Llama 3, travailler sur une base d'une telle qualité facilite la vectorisation sémantique : les faits sont exposés clairement, sans ambiguïté. En basant notre détection sur ces deux rédactions, nous garantissons à l'utilisateur que le verdict rendu, lorsque le RAG est utilisé, n'est pas une simple intuition, mais le reflet d'une réalité documentée et sourcée.

## 2.5 Nouveau Format de Sortie (Standard JSON v2)

La réponse API est désormais beaucoup plus riche, offrant une transparence totale sur le verdict :

```
{
  "verdict": "Slightly Misleading",
  "confiance": 0.85,
  "catégorie": "Politique",
  "justification": "L'article affirme que X est arrivé, mais les rapports de l'AFP
    ↪ indiquent que l'événement a été reporté.",
}
```

## 2.6 Flux final

### 2.6.1 Entrée

URL ou texte soumis par l'utilisateur.

### 2.6.2 Récupération

Le système extrait les preuves de la base de données factuelles (ChromaDB).

### 2.6.3 Travail du LLM

Llama 3 analyse le texte utilisateur au regard de l'article de notre base avec lequel il a été fournis.

### 2.6.4 Sortie

Production du JSON structuré.

## 2.7 Sécurité et Robustesse Technique

L'implémentation logicielle a été renforcée par l'ajout de nouvelles dépendances critiques :

- **Pydantic (Schemas)** : Validation stricte des entrées/sorties via `TextSchema` et `FileSchema` pour éviter les injections de données malformées.
- **Gestion des Timeouts** : Configuration de la résilience pour gérer les temps de réponse plus longs des LLM génératifs (utilisation de `wait_for_model: True`).
- **Normalisation des Environnements** : Utilisation d'un fichier `requirements.txt` hybride combinant des versions figées par `uv` et des extensions flexibles pour le RAG, garantissant la portabilité du projet.

## Partie 3

# Analyses des résultats et des performances



## Partie 4

# Marketing

### 4.1 Introduction

Dans le cadre du jalon 3, la stratégie marketing de VerifAI vise à préparer le passage d'un prototype fonctionnel à un produit réellement adopté par ses utilisateurs.

Notre application répond à un besoin croissant : vérifier rapidement la fiabilité d'un contenu (texte ou lien) dans un contexte où la désinformation circule massivement sur les plateformes numériques.

L'objectif de cette section est double :

1. Identifier précisément les utilisateurs cibles grâce à une analyse Persona.
2. Poser les bases d'une communication orientée usages réels (rapidité, simplicité, explicabilité du résultat).

Le positionnement marketing de VerifAI repose sur une promesse simple : **“vérifier avant de partager”**, avec une expérience fluide, un retour rapide et un score compréhensible.

### 4.2 Analyse Persona des utilisateurs cibles

Afin d'orienter la communication, les fonctionnalités prioritaires et les canaux d'acquisition, nous avons structuré notre ciblage autour de deux segments complémentaires : **B2C** (grand public) et **B2B** (organisations et professionnels).

#### Persona B2C — Étudiant universitaire connecté

##### Profil

- 19 à 25 ans
- Utilise quotidiennement Instagram, TikTok, X et YouTube
- Consulte souvent l'actualité via les réseaux sociaux plutôt que via les médias traditionnels

##### Besoins

- Vérifier rapidement une information avant de la repartager
- Comprendre en quelques secondes si un contenu semble crédible
- Disposer d'un outil simple, mobile-friendly et sans friction

##### Douleurs

- Surcharge informationnelle
- Difficulté à distinguer une source fiable d'un contenu viral trompeur
- Manque de temps pour faire une vérification manuelle approfondie

#### Valeur apportée par VerifAI

- Analyse rapide de texte/liens
- Verdict clair + score de confiance
- Interface intuitive adaptée à un usage quotidien
- Réduction du risque de partager involontairement une fausse information

## Persona B2B — Responsable communication / journaliste junior

### Profil

- 25 à 40 ans
- Travaille en rédaction, média étudiant, communication institutionnelle, ONG, ou agence
- Publie régulièrement de l'information pour un public large

### Besoins

- Obtenir un premier niveau de vérification avant publication
- Réduire le temps de pré-validation des contenus
- Appuyer les décisions éditoriales avec des indicateurs compréhensibles
- Disposer d'un outil simple à intégrer dans un flux de travail existant

### Douleurs

- Pression temporelle et volume de contenus à traiter
- Risque réputationnel en cas de diffusion d'information erronée
- Multiplication des sources non vérifiées
- Besoin de justifier les choix éditoriaux en interne

### Valeur apportée par VerifAI

- Outil d'aide à la décision rapide
- Résultats explicites pour justifier une vigilance éditoriale
- Complément léger aux processus de fact-checking existants
- Diminution du risque d'erreur publique et amélioration de la crédibilité de l'organisation

## 4.3 Synthèse des personas

L'analyse Persona montre que VerifAI cible deux marchés distincts mais cohérents :

1. **B2C** : utilisateurs individuels exposés à des contenus viraux, qui veulent vérifier avant de partager.
2. **B2B** : équipes de communication et de publication, qui doivent décider vite tout en réduisant le risque réputationnel.

Ces personas orientent directement la stratégie marketing :

- proposition de valeur B2C : **simple, rapide, accessible** ;
- proposition de valeur B2B : **fiable, explicable, intégrable aux pratiques éditoriales** ;
- canaux prioritaires : **réseaux sociaux et communautés étudiantes (B2C), LinkedIn, médias campus et réseaux professionnels (B2B)** ;
- ton de communication : **pédagogique, concret, orienté usage**.

## 4.4 Différenciation par rapport à la concurrence

Le marché des outils de vérification d'information est déjà occupé par plusieurs approches : plateformes de fact-checking éditorial, extensions de navigateur, moteurs de recherche enrichis et assistants IA généralistes. VerifAI ne cherche pas à remplacer ces solutions expertes ; son positionnement est celui d'un **outil de pré-vérification rapide**, accessible au quotidien.

Notre différenciation repose sur trois axes complémentaires.

### Explicabilité du résultat

Contrairement à une réponse binaire opaque, VerifAI présente un verdict accompagné d'un score de confiance, d'indicateurs lisibles et d'une explication synthétique. Cette approche facilite l'appropriation du résultat par des utilisateurs non spécialistes et répond aussi aux besoins B2B, où les décisions de publication doivent pouvoir être justifiées.

La valeur marketing est forte : l'utilisateur ne reçoit pas seulement un résultat, il comprend **pourquoi** le système propose ce résultat.

### Simplicité d'usage

La proposition produit est pensée pour réduire au maximum la friction : coller un texte ou un lien, lancer l'analyse, obtenir une synthèse claire. L'interface privilégie la lisibilité, un parcours court et des actions immédiates.

Par rapport à des outils plus complets mais plus complexes, VerifAI se distingue par un apprentissage quasi nul. Cette simplicité améliore l'adoption, notamment auprès du public étudiant et des équipes communication qui travaillent sous contrainte de temps.

### Rapidité d'usage

La rapidité est un avantage concurrentiel décisif dans un contexte de flux informationnel continu. VerifAI est conçu pour fournir un premier niveau d'analyse en quelques secondes, ce qui correspond au moment critique où l'utilisateur hésite à partager ou publier un contenu.

Cette logique "vite et utile" complète les démarches de vérification approfondie : VerifAI agit comme un premier filtre, alors que les solutions expertes interviennent ensuite pour l'analyse détaillée.

### Positionnement concurrentiel synthétique

En synthèse, VerifAI se positionne comme une solution intermédiaire entre les outils grand public très simplifiés et les approches journalistiques plus lourdes.

- Face aux fact-checkers traditionnels : VerifAI apporte la rapidité de pré-diagnostic.
- Face aux assistants IA généralistes : VerifAI propose un cadre orienté vérification, avec restitution structurée.
- Face aux extensions techniques : VerifAI privilégie une expérience claire, directe et pédagogique.

Ce positionnement permet de défendre une promesse concrète et différenciante : **une vérification explicable, simple et rapide, adaptée aux usages réels de partage d'information.**

## 4.5 Page web de l'application

La page web de VerifAI constitue le principal point de contact avec l'utilisateur. Dans notre stratégie marketing, elle joue un double rôle : convertir la curiosité en usage réel et installer la confiance dès les premières secondes d'interaction.

L'interface est orientée produit et pensée pour un usage immédiat : parcours court, lisibilité élevée et restitution compréhensible du verdict.

La page introduit une identité visuelle claire (branding VerifAI), une hiérarchie d'information lisible et un parcours simplifié. L'utilisateur peut saisir un texte ou une URL, lancer l'analyse rapidement et comprendre le verdict sans ambiguïté grâce à une restitution structurée (score de confiance, métriques, explication synthétique).

Cette page soutient directement nos deux cibles marketing. Côté B2C, la simplicité réduit la friction et favorise l’usage spontané. Côté B2B, la clarté de la restitution facilite la prise de décision et améliore la crédibilité perçue de l’outil dans un contexte de publication.

En résumé, la page web actuelle transforme VerifAI d’un prototype technique en produit crédible, compréhensible et aligné avec notre promesse marketing : vérifier avant de partager, de façon simple, rapide et explicable.

## 4.6 Présence sur les plateformes sociales

La présence sociale de VerifAI a pour objectif de transformer un besoin diffus (“je veux éviter de partager de la désinformation”) en réflexe concret d’utilisation. La ligne éditoriale retenue repose sur deux leviers complémentaires : des formats de **démonstration produit** pour montrer la valeur immédiate, et des formats de **vulgarisation** pour éduquer sans complexifier.

### Positionnement éditorial

La communication adopte un ton clair, pédagogique et orienté usage. Le message central reste constant : **vérifier avant de partager**. Chaque publication doit répondre à une question simple de l’utilisateur : “Qu’est-ce que VerifAI m’apporte maintenant, en pratique ?”

Cette cohérence permet de renforcer la mémorisation de la marque et de créer une continuité entre le contenu social, la page web et l’expérience produit.

### Formats démo

Les contenus de démonstration montrent l’application en situation réelle, avec un parcours court de bout en bout : saisie d’un texte ou d’une URL, lancement de l’analyse, lecture du verdict.

- vidéos courtes avant/après analyse ;
- vidéos courtes de démonstration d’analyse ;
- captures commentées de l’interface et du score ;
- mini-cas d’usage “vu sur les réseaux” traités en moins d’une minute ;
- démonstrations comparant une information fiable et une information douteuse.

Ces formats servent principalement l’acquisition B2C, car ils rendent la proposition de valeur immédiatement visible.

### Formats de vulgarisation

La vulgarisation complète la démonstration en expliquant les bons réflexes informationnels et la lecture des résultats. L’objectif n’est pas de former à l’IA en profondeur, mais de rendre l’utilisateur autonome dans ses décisions quotidiennes.

- carrousels “comment repérer un signal de désinformation” ;
- posts “mythe vs réalité” sur la fiabilité des sources ;
- capsules “comment interpréter un score de confiance” ;
- publications pédagogiques liées à l’actualité numérique.

Ces formats favorisent la crédibilité de VerifAI et soutiennent aussi la cible B2B, sensible à la qualité du cadre explicatif.

### Plateformes prioritaires

Le déploiement social est adapté aux deux segments de ciblage. Pour le B2C, les plateformes visuelles et rapides (Instagram, TikTok, X) sont privilégiées, avec des contenus courts et démonstratifs. Pour le B2B, LinkedIn et les communautés professionnelles/campus sont plus pertinents, avec des contenus orientés méthode, fiabilité et cas d’usage.

L'enjeu n'est pas d'être présent partout, mais d'être régulier là où les personas consomment déjà de l'information.

### **Effet attendu**

Une présence sociale cohérente autour de la démo et de la vulgarisation doit produire trois effets marketing : augmenter la notoriété de VerifAI, améliorer la confiance envers l'outil et générer des visites qualifiées vers la page web de l'application.

En résumé, les réseaux sociaux deviennent un prolongement direct du produit : ils montrent, expliquent et donnent envie d'utiliser VerifAI dans des situations réelles.

## **4.7 Stratégie de collaborations et de publicités**

Pour accélérer l'adoption de VerifAI, la stratégie de croissance combine des collaborations ciblées et des actions publicitaires légères. L'objectif n'est pas de maximiser le volume à court terme, mais d'obtenir une acquisition qualifiée, cohérente avec la promesse du produit : vérifier rapidement et comprendre clairement un résultat.

### **Collaborations prioritaires**

Les collaborations sont pensées comme des relais de confiance. En phase initiale, VerifAI peut s'appuyer sur des partenaires proches des personas identifiés : associations étudiantes, médias campus, clubs de journalisme, enseignants impliqués en éducation aux médias, ainsi que structures de communication locale.

Le principe est simple : proposer des démonstrations concrètes, des ateliers courts et des formats co-brandés. Ce type de partenariat favorise un bouche-à-oreille crédible et permet de tester le produit dans des contextes réels d'usage.

### **Logique B2C et logique B2B**

En B2C, les collaborations doivent créer de la proximité et de la preuve d'utilité immédiate. Les actions les plus pertinentes sont les démonstrations en milieu étudiant, les contenus co-crésés avec des créateurs orientés vulgarisation et les challenges communautaires autour du réflexe "vérifier avant de partager".

En B2B, la priorité est la crédibilité opérationnelle. Les partenariats visent des médias étudiants, des organismes de sensibilisation et des équipes communication qui peuvent intégrer VerifAI comme outil de pré-vérification dans leur flux de publication.

### **Publicité digitale à faible budget**

La publicité payante intervient en complément des collaborations, avec un ciblage précis et des budgets maîtrisés. Les campagnes sont principalement orientées vers des contenus démo (vidéos courtes, captures commentées, cas concrets) afin de montrer la valeur en quelques secondes.

- sur Instagram/TikTok/X pour l'acquisition B2C ;
- sur LinkedIn pour la notoriété et la génération de contacts B2B ;
- avec redirection vers la page web pour tester l'outil immédiatement.

Le message publicitaire reste constant : "vérifier avant de partager", avec un accent sur la simplicité d'usage et l'explicabilité du résultat.

### **Indicateurs de performance**

L'évaluation des collaborations et publicités repose sur des indicateurs concrets : taux de clic, coût d'acquisition, taux d'essai de l'outil, part d'utilisateurs récurrents et retours qualitatifs des partenaires.

Cette mesure continue permet d'identifier les canaux les plus efficaces et d'ajuster rapidement les actions marketing sans perdre la cohérence stratégique.

## **Synthèse**

La stratégie collaborations/publicités de VerifAI privilégie la confiance, la preuve d'usage et la régularité. Les collaborations apportent la crédibilité et l'ancrage terrain ; la publicité apporte l'amplification ciblée. Ensemble, ces deux leviers soutiennent une croissance progressive et réaliste, alignée avec les segments B2C et B2B.

## Partie 5

# Conclusion

Le développement de VerifAI pour ce jalon 3 a permis de démontrer la faisabilité d'un outil de fact-checking automatisé alliant précision technique et clarté pédagogique. Le passage d'un modèle de classification rigide (RoBERTa) à un grand modèle de langage (Llama 3) couplé à une architecture RAG a radicalement transformé l'expérience utilisateur : le verdict n'est plus une simple intuition statistique, mais le résultat d'un raisonnement s'appuyant sur des faits documentés.

Sur le plan commercial, l'analyse marketing a révélé un besoin critique pour une solution capable de vulgariser la vérification d'information pour le grand public tout en offrant la robustesse nécessaire aux professionnels de la communication. L'intégration d'une interface web moderne et la capacité de traiter divers formats (URL, fichiers PDF, texte brut) positionnent VerifAI comme un outil polyvalent dans la lutte contre la désinformation.

Bien que des défis subsistent, notamment en termes de temps de réponse des modèles génératifs et de diversité des sources de référence, les bases d'un produit commercial complet sont désormais établies. Les prochaines étapes se concentreront sur l'optimisation des performances techniques et l'élargissement de la base de données de faits pour couvrir une actualité toujours plus dense et complexe.

# Références

- Kermani, Arshia, Veronica Perez-Rosas, et Vangelis Metsis. 2025. « A Systematic Evaluation of LLM Strategies for Mental Health Text Analysis : Fine-tuning vs. Prompt Engineering vs. RAG ». Prépublié mars 31. <https://doi.org/10.48550/arXiv.2503.24307>.
- Ovadia, Oded, Menachem Brief, Moshik Mishaeli, et Oren Elisha. 2024. « Fine-Tuning or Retrieval ? Comparing Knowledge Injection in LLMs ». Prépublié janvier 30. <https://doi.org/10.48550/arXiv.2312.05934>.
- Pornprasit, Chanathip, et Chakkrit Tantithamthavorn. 2024. « Fine-Tuning and Prompt Engineering for Large Language Models-based Code Review Automation ». Prépublié juin 17. <https://doi.org/10.48550/arXiv.2402.00905>.
- Shin, Jiho, Clark Tang, Tahmineh Mohati, Maleknaz Nayebi, Song Wang, et Hadi Hemmati. 2025. « Prompt Engineering or Fine-Tuning : An Empirical Assessment of LLMs for Code ». Prépublié février 19. <https://doi.org/10.48550/arXiv.2310.10508>.
- Vangibhurathachhi, Srinivasa Kalyan. 2025. « Adapting Large Language Models : A Comparative Study of Prompt Engineering and Fine-Tuning ». *International Journal of Emerging Research in Engineering and Technology* 6 (3) : 9-15. <https://doi.org/10.63282/3050-922X.IJERET-V6I3P102>.