



Université du Québec
à Chicoutimi

Jalon 3

8INF970 — Atelier pratique en cybersécurité II

Fehmi Jaafar Samuel Desbiens

Justin Bossard

Mattéo Gouhier

Paul Mathé

Samuel Plet

Léo Raclet

7 avril 2026

Table des matières

1	Introduction	2
2	Évolution vers une Architecture Hybride (RAG & LLM)	3
2.1	Changement de Paradigme : De RoBERTa à Llama 3	3
2.2	Abandon du Fine-Tuning au profit du Prompt Engineering	3
2.3	Le Système de Mémoire : Architecture RAG	4
2.4	Explication du choix des données	5
2.5	Nouveau Format de Sortie (Standard JSON v2)	5
2.6	Flux final	5
2.7	Sécurité et Robustesse Technique	5
3	Analyses des résultats et des performances	7
3.1	Métriques globales	7
3.2	Performance par session	8
3.3	Répartition des résultats	9
3.4	Analyse de la confiance	10
3.5	Énoncés problématiques récurrents	11
3.5.1	Théories du complot plausibles en surface	12
3.5.2	Absurdités à formulation naïve	12
3.5.3	Affirmations ambiguës mal gérées	12
3.6	Points forts du système	12
3.7	Faiblesses identifiées	12
3.8	Recommandations	12
3.9	Conclusion	13
4	Marketing	14
4.1	Analyse Persona des utilisateurs cibles	14
4.2	Synthèse des personas	15
4.3	Différenciation par rapport à la concurrence	15
4.4	Page web de l'application	16
4.5	Présence sur les plateformes sociales	17
4.6	Stratégie de collaborations et de publicités	18
5	Conclusion	20
	Références	21

Partie 1

Introduction

L'objectif de ce troisième jalon est de transformer le prototype initial de VerifAI en un produit commercial viable. Alors que les itérations précédentes se concentraient sur une classification binaire simple, cette étape marque une évolution significative vers une architecture hybride de Génération Augmentée par Récupération (RAG). Cette approche permet non seulement d'évaluer la véracité d'un contenu, mais également de fournir une justification détaillée et sourcée à l'utilisateur.

Le présent rapport documente :

- L'amélioration de l'intelligence artificielle par le passage au modèle Llama 3 et l'intégration d'une base de données vectorielle ChromaDB, alimentée par des sources de presse officielles.
- L'analyse des résultats et des performances du produit.
- L'analyse de la stratégie marketing, incluant l'étude des personas cibles et le positionnement concurrentiel du produit.
- L'évaluation technique des résultats obtenus avec cette nouvelle architecture.

Partie 2

Évolution vers une Architecture Hybride (RAG & LLM)

Pour dépasser les limites d’une simple classification “Vrai/Faux”, l’architecture a évolué vers un système de **Génération Augmentée par Récupération (RAG)**. Cette approche permet non seulement de détecter la désinformation, mais aussi de fournir une justification sourcée en se basant sur des faits réels et actualisés.

2.1 Changement de Paradigme : De RoBERTa à Llama 3

Initialement basé sur RoBERTa pour la classification, le système utilise désormais **Llama 3**. Ce changement est motivé par deux besoins :

- **Le Raisonnement** : Capacité à expliquer *pourquoi* une information est jugée suspecte. RoBERTa ne donnait qu’une réponse Vrai/Faux, mais Llama, en tant que LLM, permet de justifier le choix.
- **Le Contexte** : Capacité à comprendre le contexte global de l’article, et pas seulement une phrase isolée.

2.2 Abandon du Fine-Tuning au profit du Prompt Engineering

La stratégie initiale envisageait un fine-tuning supervisé (SFT) sur un jeu de données spécifique. Cette approche a été écartée au profit du *Prompt Engineering* couplé à l’architecture RAG, en raison de plusieurs contraintes techniques et méthodologiques.

Bien que non retenu pour l’itération actuelle, le fine-tuning supervisé présente des avantages documentés. En termes de performance et de précision, comme le démontrent Shin et al. (2025), les modèles fine-tunés peuvent surpasser significativement les approches de prompt engineering (jusqu’à 28 points sur certains benchmarks), offrant une stabilité supérieure pour des tâches hautement spécialisées. De plus, l’entraînement permet de contraindre le modèle à générer systématiquement une structure JSON exacte, limitant ainsi les erreurs de syntaxe. Cette méthode optimise également l’inférence en internalisant les règles de formatage, ce qui réduit le nombre de tokens nécessaires en entrée et diminue le temps d’apparition du premier mot (*Time To First Token*). Enfin, les méthodes PEFT (comme LoRA) permettent d’obtenir des performances élevées sur des modèles de taille modeste tout en réduisant les coûts de calcul, offrant un compromis optimal entre précision et ressources (Vangibhurathachhi 2025).

Cependant, la mise en œuvre de cette méthode s’est heurtée à la difficulté de constituer un ensemble de données adéquat. Trois sources principales avaient été identifiées initialement : Webz.io (un répertoire de contenus thématiques), ISOT (un jeu de données binaire d’articles réels et factices) et FakeNewsNet

(un dépôt de données vérifiées de PolitiFact et GossipCop). Pour générer un dataset performant, il est impératif de coupler chaque article à son verdict et à une justification textuelle précise. Or, ces bases manquent de la justification native nécessaire. L’exploitation de Webz.io a été écartée en raison d’un volume brut excédant les ressources matérielles et de l’absence de verdicts validés par des experts. FakeNewsNet, malgré ses labels clairs, souffre quant à lui d’une absence totale de justifications textuelles.

Puisque le fine-tuning exige des ressources importantes et des données volumineuses de haute qualité, l’absence de justifications natives aurait rendu nécessaire l’usage de données synthétiques. Cette alternative introduit des risques critiques de biais. D’une part, la généralisation abusive via des justifications stéréotypées peut limiter le modèle à reproduire des patrons de phrases au lieu d’analyser le texte. D’autre part, forcer la génération de justifications complexes sans lien direct avec les faits réels crée une incohérence sémantique qui augmente drastiquement le risque d’introduire des hallucinations dans le dataset. Par ailleurs, l’usage d’un dataset restreint forcerait une mémorisation d’exemples spécifiques (surapprentissage ou *overfitting*) au détriment de la logique de détection universelle.

Outre la problématique des données, le recours au fine-tuning s’est avéré être une démarche superflue face aux capacités des modèles récents. Le système repose désormais sur Llama 3 (version Instruct), un modèle nativement optimisé pour suivre des directives complexes et produire des formats de sortie stricts comme le JSON. Réentraîner les poids d’un modèle de plusieurs milliards de paramètres uniquement pour lui imposer une structure de réponse représente un effort disproportionné par rapport aux gains attendus.

Par conséquent, le passage au *Prompt Engineering* et au RAG a été privilégié pour la flexibilité accrue qu’il offre. Comme le soulignent Kermani et al. (2025), le prompt engineering et le RAG permettent une adaptation rapide et un déploiement plus flexible, particulièrement adaptés aux scénarios nécessitant une généralisation. Cette approche facilite également la gestion des ressources ; Pornprasit et Tantithamthavorn (2024) recommandent l’approche *few-shot* lorsque les données sont insuffisantes pour un fine-tuning complet, permettant une performance modérée avec une consommation de ressources réduite. De plus, elle assure une séparation claire des préoccupations en intégrant des informations externes actuelles via une base vectorielle (ChromaDB). Comme le confirment Ovadia et al. (2024), l’injection de connaissances par récupération (RAG) est plus adaptée que le fine-tuning pour gérer des données dynamiques, laissant ainsi le modèle se concentrer sur l’analyse logique. Enfin, la maintenance est grandement simplifiée, car l’ajustement des prompts en temps réel évite les cycles d’entraînement chronophages et la lourde gestion de fichiers de modèles.

2.3 Le Système de Mémoire : Architecture RAG

L’innovation majeure réside dans l’ajout d’une “mémoire factuelle” qui permet à l’IA de consulter des sources de confiance avant de répondre.

- **Scraping RSS** : Le système n’est plus statique. Un module de collecte automatisé (`scripts/fetch_news.py`) s’exécute tous les jours pour parcourir les flux **RSS** de sources de presse reconnues (Le Monde et France 24). Grâce aux bibliothèques **Feedparser** et **Newspaper3k**, le contenu textuel est extrait, nettoyé de ses balises HTML, et centralisé dans un dataset de référence.
- **Vectorisation et Stockage (ChromaDB)** : Pour que l’IA puisse “chercher” dans ces milliers d’articles, nous utilisons :
 - **Sentence-Transformers (all-MiniLM-L6-v2)** : Ce modèle transforme chaque article de presse en un vecteur mathématique de 384 dimensions représentant son sens sémantique.
 - **ChromaDB** : Une base de données vectorielle haute performance qui stocke ces vecteurs. Elle permet de trouver rapidement les articles les plus proches sémantiquement de la requête de l’utilisateur.

- **Prompt Enrichi** : Maintenant, avant chaque requête, on récupère l'article de notre base le plus proche sémantiquement du texte à analyser, ainsi qu'un score de similitude. Si ce score dépasse le seuil mis en place, l'article est envoyé comme source dans la requête à notre LLM, pour qu'il rende son verdict avec les informations actuelles. Dans le cas contraire, seulement l'information dont on demande une vérification est envoyée dans le prompt, pour éviter que le LLM se base sur un article qui n'a pas de rapport, et donc répondre que comme les articles sont sur des sujets différents, l'information est fausse.

2.4 Explication du choix des données

Le succès d'un système RAG repose sur la fiabilité des sources. En choisissant France 24 et Le Monde, on ne prendra pas seulement des flux de données d'informations, mais on s'assure de la qualité des vérifications. Ces deux rédactions sont reconnues pour avoir des informations sourcées et recoupées, ce qui est indispensable pour servir de base pour notre projet.

L'intérêt majeur réside dans leur complémentarité. D'un côté, France 24 produit des articles en continu sur les sujets d'actualités, donc cela nous assure une réactivité immédiate sur les événements mondiaux. De l'autre, Le Monde apporte, avec des articles moins nombreux mais plus développés, une profondeur d'analyse et une rigueur plus grande. Ce binôme permet au modèle de disposer d'une base de connaissances équilibrée, capable de traiter aussi bien une information extrêmement récente, comme aller chercher les détails précis d'une autre information.

Enfin, il y a un enjeu linguistique et technique. Ces sources produisent des textes très bien écrits, cela nous semble pouvoir aider à réduire des biais sensationnalistes. Pour notre modèle Llama 3, travailler sur une base d'une telle qualité facilite la vectorisation sémantique : les faits sont exposés clairement, sans ambiguïté. En basant notre détection sur ces deux rédactions, nous garantissons à l'utilisateur que le verdict rendu, lorsque le RAG est utilisé, n'est pas une simple intuition, mais le reflet d'une réalité documentée et sourcée.

2.5 Nouveau Format de Sortie (Standard JSON v2)

La réponse API est désormais beaucoup plus riche, offrant une transparence totale sur le verdict :

```
{
  "verdict": "Slightly Misleading",
  "confiance": 0.85,
  "catégorie": "Politique",
  "justification": "L'article affirme que X est arrivé, mais les rapports de l'AFP
    ↪ indiquent que l'événement a été reporté.",
}
```

2.6 Flux final

1. **Entrée** : URL ou texte soumis par l'utilisateur.
2. **Récupération** : Le système extrait les preuves de la base de données factuelles (ChromaDB).
3. **Travail du LLM** : Llama 3 analyse le texte utilisateur au regard de l'article de notre base avec lequel il a été fourni.
4. **Sortie** : Production du JSON structuré.

2.7 Sécurité et Robustesse Technique

L'implémentation logicielle a été renforcée par l'ajout de nouvelles dépendances critiques :

- **Pydantic (Schemas)** : Validation stricte des entrées/sorties via `TextSchema` et `FileSchema` pour éviter les injections de données malformées.
- **Gestion des Timeouts** : Configuration de la résilience pour gérer les temps de réponse plus longs des LLM génératifs (utilisation de `wait_for_model: True`).
- **Normalisation des Environnements** : Utilisation d'un fichier `requirements.txt` hybride combinant des versions figées par `uv` et des extensions flexibles pour le RAG, garantissant la portabilité du projet.

Partie 3

Analyses des résultats et des performances

VerifAI a été soumis à cinq sessions de test consécutives sous forme de validation croisée, à partir d'un dataset de 50 articles. Chaque session présente un ensemble d'énoncés variés - faits vérifiables, désinformations grossières, théories du complot et affirmations ambiguës - auxquels le modèle répond par une classification (VRAI, FAUX ou PARTIEL) accompagnée d'un score de confiance.

Ce rapport évalue la performance globale du système, identifie ses forces et faiblesses, et propose des pistes d'amélioration ciblées.

3.1 Métriques globales

Indicateur	Valeur
Énoncés évalués (total)	155
Précision globale	72 %
Taux de vrais positifs (VRAI détecté correctement)	95 %
Taux de vrais négatifs (FAUX rejeté correctement)	56 %
Taux d'erreur global	28 %
Faux positifs (FAUX classé VRAI)	~35 cas
Faux négatifs (VRAI classé PARTIEL ou FAUX)	~9 cas

La précision de 72 % constitue un point de départ solide. Le modèle excelle à valider les faits vrais (95 % de détection), mais peine à rejeter les désinformations : seulement 56 % des énoncés faux sont correctement identifiés comme tels.

3.2 Performance par session




FIGURE 3.1 : Précision par session

Session	Énoncés	Succès	Précision
Session 1	28	20	71 %
Session 2	30	18	60 %
Session 3	29	20	69 %
Session 4	30	22	73 %
Session 5	29	21	72 %

La session 2 constitue le creux de performance (60 %), notamment due à une forte proportion de prédictions **PARTIEL** appliquées à des énoncés clairement **FAUX**. Les sessions 4 et 5 montrent une amélioration notable, suggérant une certaine robustesse du modèle sur des ensembles diversifiés.

3.3 Répartition des résultats

Répartition des résultats — toutes sessions




FIGURE 3.2 : Répartition des résultats - toutes sessions

La matrice de confusion révèle un déséquilibre clair : les vrais positifs (67) dominent largement, tandis que les faux positifs (35) constituent la principale source d'erreur. Les faux négatifs (9) restent rares mais préoccupants en raison de leur niveau de confiance élevé.

3.4 Analyse de la confiance




FIGURE 3.3 : Confiance moyenne par type de résultat

Le comportement du score de confiance révèle un patron cohérent :

- **Vrais positifs** : confiance moyenne de **86 %** - le modèle est bien calibré sur les faits vérifiables.
- **Vrais négatifs** : confiance moyenne de **23 %** - la faible confiance sert efficacement d'indicateur de rejet pour les désinformations bien reconnues.
- **Faux positifs** : confiance moyenne de **33 %** - les erreurs sur les fausses informations se produisent surtout à faible confiance, ce qui laisse ouverte une stratégie de seuillage.
- **Faux négatifs** : confiance moyenne de **71 %** - problème plus sérieux : le modèle se trompe avec une haute confiance sur certains faits vrais.

Distribution de la confiance (VRAI vs FAUX attendu)




FIGURE 3.4 : Distribution de la confiance

Interprétation clé : la confiance n'est pas encore un indicateur fiable d'exactitude pour les énoncés faux. Un score de 20 % peut correspondre à une bonne détection *ou* à un rejet injustifié d'une information vraie. En revanche, les énoncés vrais sont quasi systématiquement associés à une confiance ≥ 80 %.

3.5 Énoncés problématiques récurrents

Énoncés problématiques récurrents (≥ 2 sessions en erreur)




FIGURE 3.5 : Énoncés problématiques récurrents

Certains énoncés ont échoué dans plusieurs sessions, révélant des angles morts systématiques du modèle.

3.5.1 Théories du complot plausibles en surface

Ces énoncés combinent un vocabulaire scientifique ou officiel avec une conclusion fausse. Le modèle les classe incorrectement en **VRAI** dans 3 à 4 sessions sur 5 :

- “*Les cheveux et les ongles continuent de pousser après la mort*” - mythe médical courant, échoue dans 4 sessions.
- “*La technologie 5G est directement responsable de la mort d’oiseaux migrants*” - 3 sessions en erreur.
- “*L’homme n’a jamais marché sur la Lune*” - 3 sessions en erreur, avec une confiance élevée (70 %).

3.5.2 Absurdités à formulation naïve

Paradoxalement, certains énoncés manifestement faux mais formulés de façon fantaisiste échappent au modèle :

- “*Les requins sont des robots espions*” - classé **VRAI** dans 3 sessions.
- “*Les oiseaux sont des drones de surveillance*” - 3 sessions en erreur.

Ces cas suggèrent que le modèle s’appuie peu sur la vraisemblance de base et davantage sur des marqueurs linguistiques de surface.

3.5.3 Affirmations ambiguës mal gérées

L’usage de la prédiction **PARTIEL** est appliqué de façon incohérente, parfois sur des énoncés entièrement faux (*traînées d’avions, télécharger Internet sur USB*) et parfois sur des faits vrais (*cœur humain*). Cette catégorie nécessite une définition plus stricte.

3.6 Points forts du système

- **Faits scientifiques établis** : photosynthèse, gravité, ébullition de l’eau, HTTPS, ransomware - précision quasi parfaite, confiance bien calibrée (80–100 %).
- **Désinformations grossières** : pyramides extraterrestres, Terre plate, eau de Javel curative - rejetées systématiquement et correctement.
- **Domaine cybersécurité** : détection fiable et confiante sur tous les énoncés techniques testés.
- **Faits géographiques et institutionnels** : Paris, OMS, Japon, UQAC - aucune erreur observée.

3.7 Faiblesses identifiées

Catégorie	Problème	Impact
Théories du complot à vernis scientifique	Taux de faux positifs élevé	Élevé
Prédictions PARTIEL inconsistantes	Manque de critères clairs	Moyen
Haute confiance sur faux négatifs	Erreurs difficiles à filtrer a posteriori	Élevé
Absurdités formulées simplement	Contournement du filtre sémantique	Moyen

3.8 Recommandations

R1 - Introduire un seuil de rejet basé sur la confiance Les faux positifs apparaissent majoritairement à confiance ≤ 30 %. Configurer le système pour retourner une réponse **INCERTAIN** lorsque la

confiance est inférieure à 35 % réduirait les erreurs sans dégrader la précision sur les vrais positifs.

R2 - Renforcer la base d'entraînement sur les théories du complot Augmenter les exemples d'énoncés à structure pseudo-scientifique étiquetés FAUX, en particulier ceux liés aux vaccins, aux technologies de communication (5G) et aux théories géopolitiques.

R3 - Standardiser la catégorie PARTIEL Définir des critères formels d'utilisation : PARTIEL ne devrait s'appliquer qu'aux énoncés dont une partie est vérifiable et l'autre non, jamais à des énoncés entièrement faux ou entièrement vrais.

R4 - Intégrer un module de vraisemblance de base Les énoncés absurdes (requins robots, oiseaux drones) devraient déclencher un signal de rejet préemptif fondé sur la cohérence ontologique, avant toute analyse sémantique fine.

R5 - Tests adversariaux systématiques Constituer un jeu de données dédié aux énoncés « limite », reformulés pour maximiser la vraisemblance de surface tout en étant faux, et les intégrer à chaque cycle d'évaluation.

3.9 Conclusion

VerifAI démontre une performance solide sur les faits établis et les désinformations évidentes, avec une précision globale de 72 % sur 155 énoncés hétérogènes. La principale vulnérabilité réside dans la gestion des fausses informations formulées de manière crédible ou pseudo-scientifique. Les pistes d'amélioration identifiées - seuillage par confiance, enrichissement des données d'entraînement et standardisation du label PARTIEL - sont toutes implémentables à court terme et devraient permettre d'atteindre une précision cible de 85 % lors des prochains cycles de test.

Partie 4

Marketing

Dans le cadre du jalon 3, la stratégie marketing de VerifAI vise à préparer le passage d'un prototype fonctionnel à un produit réellement adopté par ses utilisateurs.

Notre application répond à un besoin croissant : vérifier rapidement la fiabilité d'un contenu (texte ou lien) dans un contexte où la désinformation circule massivement sur les plateformes numériques.

L'objectif de cette section est double :

1. Identifier précisément les utilisateurs cibles grâce à une analyse Persona.
2. Poser les bases d'une communication orientée usages réels (rapidité, simplicité, explicabilité du résultat).

Le positionnement marketing de VerifAI repose sur une promesse simple : **“vérifier avant de partager”**, avec une expérience fluide, un retour rapide et un score compréhensible.

4.1 Analyse Persona des utilisateurs cibles

Afin d'orienter la communication, les fonctionnalités prioritaires et les canaux d'acquisition, nous avons structuré notre ciblage autour de deux segments complémentaires : **B2C** (grand public) et **B2B** (organisations et professionnels).

Persona B2C — Étudiant universitaire connecté

Profil

- 19 à 25 ans
- Utilise quotidiennement Instagram, TikTok, X et YouTube
- Consulte souvent l'actualité via les réseaux sociaux plutôt que via les médias traditionnels

Besoins

- Vérifier rapidement une information avant de la repartager
- Comprendre en quelques secondes si un contenu semble crédible
- Disposer d'un outil simple, mobile-friendly et sans friction

Douleurs

- Surcharge informationnelle
- Difficulté à distinguer une source fiable d'un contenu viral trompeur
- Manque de temps pour faire une vérification manuelle approfondie

Valeur apportée par VerifAI

- Analyse rapide de texte/liens

- Verdict clair + score de confiance
- Interface intuitive adaptée à un usage quotidien
- Réduction du risque de partager involontairement une fausse information

Persona B2B — Responsable communication / journaliste junior

Profil

- 25 à 40 ans
- Travaille en rédaction, média étudiant, communication institutionnelle, ONG, ou agence
- Publie régulièrement de l'information pour un public large

Besoins

- Obtenir un premier niveau de vérification avant publication
- Réduire le temps de pré-validation des contenus
- Appuyer les décisions éditoriales avec des indicateurs compréhensibles
- Disposer d'un outil simple à intégrer dans un flux de travail existant

Douleurs

- Pression temporelle et volume de contenus à traiter
- Risque réputationnel en cas de diffusion d'information erronée
- Multiplication des sources non vérifiées
- Besoin de justifier les choix éditoriaux en interne

Valeur apportée par VerifAI

- Outil d'aide à la décision rapide
- Résultats explicites pour justifier une vigilance éditoriale
- Complément léger aux processus de fact-checking existants
- Diminution du risque d'erreur publique et amélioration de la crédibilité de l'organisation

4.2 Synthèse des personas

L'analyse Persona montre que VerifAI cible deux marchés distincts mais cohérents :

1. **B2C** : utilisateurs individuels exposés à des contenus viraux, qui veulent vérifier avant de partager.
2. **B2B** : équipes de communication et de publication, qui doivent décider vite tout en réduisant le risque réputationnel.

Ces personas orientent directement la stratégie marketing :

- proposition de valeur B2C : **simple, rapide, accessible** ;
- proposition de valeur B2B : **fiable, explicable, intégrable aux pratiques éditoriales** ;
- canaux prioritaires : **réseaux sociaux et communautés étudiantes (B2C), LinkedIn, médias campus et réseaux professionnels (B2B)** ;
- ton de communication : **pédagogique, concret, orienté usage**.

4.3 Différenciation par rapport à la concurrence

Le marché des outils de vérification d'information est déjà occupé par plusieurs approches : plateformes de fact-checking éditorial, extensions de navigateur, moteurs de recherche enrichis et assistants IA généralistes. VerifAI ne cherche pas à remplacer ces solutions expertes ; son positionnement est celui d'un **outil de pré-vérification rapide**, accessible au quotidien.

Notre différenciation repose sur trois axes complémentaires.

Explicabilité du résultat

Contrairement à une réponse binaire opaque, VerifAI présente un verdict accompagné d'un score de confiance, d'indicateurs lisibles et d'une explication synthétique. Cette approche facilite l'appropriation du résultat par des utilisateurs non spécialistes et répond aussi aux besoins B2B, où les décisions de publication doivent pouvoir être justifiées.

La valeur marketing est forte : l'utilisateur ne reçoit pas seulement un résultat, il comprend **pourquoi** le système propose ce résultat.

Simplicité d'usage

La proposition produit est pensée pour réduire au maximum la friction : coller un texte ou un lien, lancer l'analyse, obtenir une synthèse claire. L'interface privilégie la lisibilité, un parcours court et des actions immédiates.

Par rapport à des outils plus complets mais plus complexes, VerifAI se distingue par un apprentissage quasi nul. Cette simplicité améliore l'adoption, notamment auprès du public étudiant et des équipes communication qui travaillent sous contrainte de temps.

Rapidité d'usage

La rapidité est un avantage concurrentiel décisif dans un contexte de flux informationnel continu. VerifAI est conçu pour fournir un premier niveau d'analyse en quelques secondes, ce qui correspond au moment critique où l'utilisateur hésite à partager ou publier un contenu.

Cette logique "vite et utile" complète les démarches de vérification approfondie : VerifAI agit comme un premier filtre, alors que les solutions expertes interviennent ensuite pour l'analyse détaillée.

Positionnement concurrentiel synthétique

En synthèse, VerifAI se positionne comme une solution intermédiaire entre les outils grand public très simplifiés et les approches journalistiques plus lourdes.

- Face aux fact-checkers traditionnels : VerifAI apporte la rapidité de pré-diagnostic.
- Face aux assistants IA généralistes : VerifAI propose un cadre orienté vérification, avec restitution structurée.
- Face aux extensions techniques : VerifAI privilégie une expérience claire, directe et pédagogique.

Ce positionnement permet de défendre une promesse concrète et différenciante : **une vérification explicable, simple et rapide, adaptée aux usages réels de partage d'information.**

4.4 Page web de l'application

La page web de VerifAI constitue le principal point de contact avec l'utilisateur. Dans notre stratégie marketing, elle joue un double rôle : convertir la curiosité en usage réel et installer la confiance dès les premières secondes d'interaction.

L'interface est orientée produit et pensée pour un usage immédiat : parcours court, lisibilité élevée et restitution compréhensible du verdict.

La page introduit une identité visuelle claire (branding VerifAI), une hiérarchie d'information lisible et un parcours simplifié. L'utilisateur peut saisir un texte ou une URL, lancer l'analyse rapidement et comprendre le verdict sans ambiguïté grâce à une restitution structurée (score de confiance, métriques, explication synthétique).

Cette page soutient directement nos deux cibles marketing. Côté B2C, la simplicité réduit la friction et favorise l'usage spontané. Côté B2B, la clarté de la restitution facilite la prise de décision et améliore la crédibilité perçue de l'outil dans un contexte de publication.

En résumé, la page web actuelle transforme VerifAI d'un prototype technique en produit crédible, compréhensible et aligné avec notre promesse marketing : vérifier avant de partager, de façon simple, rapide et explicable.




FIGURE 4.1 : Page d'accueil de VerifAI




FIGURE 4.2 : Page de résultats de VerifAI

4.5 Présence sur les plateformes sociales

La présence sociale de VerifAI a pour objectif de transformer un besoin diffus (“je veux éviter de partager de la désinformation”) en réflexe concret d'utilisation. La ligne éditoriale retenue repose sur deux leviers complémentaires : des formats de **démonstration produit** pour montrer la valeur immédiate, et des formats de **vulgarisation** pour éduquer sans complexifier.

Positionnement éditorial

La communication adopte un ton clair, pédagogique et orienté usage. Le message central reste constant : **vérifier avant de partager**. Chaque publication doit répondre à une question simple de l'utilisateur : “Qu'est-ce que VerifAI m'apporte maintenant, en pratique?”

Cette cohérence permet de renforcer la mémorisation de la marque et de créer une continuité entre le contenu social, la page web et l'expérience produit.

Formats démo

Les contenus de démonstration montrent l'application en situation réelle, avec un parcours court de bout en bout : saisie d'un texte ou d'une URL, lancement de l'analyse, lecture du verdict.

- vidéos courtes avant/après analyse ;
- vidéos courtes de démonstration d'analyse ;
- captures commentées de l'interface et du score ;
- mini-cas d'usage “vu sur les réseaux” traités en moins d'une minute ;
- démonstrations comparant une information fiable et une information douteuse.

Ces formats servent principalement l'acquisition B2C, car ils rendent la proposition de valeur immédiatement visible.

Formats de vulgarisation

La vulgarisation complète la démonstration en expliquant les bons réflexes informationnels et la lecture des résultats. L'objectif n'est pas de former à l'IA en profondeur, mais de rendre l'utilisateur autonome dans ses décisions quotidiennes.

- carrousels “comment repérer un signal de désinformation” ;
- posts “mythe vs réalité” sur la fiabilité des sources ;
- capsules “comment interpréter un score de confiance” ;
- publications pédagogiques liées à l'actualité numérique.

Ces formats favorisent la crédibilité de VerifAI et soutiennent aussi la cible B2B, sensible à la qualité du cadre explicatif.

Plateformes prioritaires

Le déploiement social est adapté aux deux segments de ciblage. Pour le B2C, les plateformes visuelles et rapides (Instagram, TikTok, X) sont privilégiées, avec des contenus courts et démonstratifs. Pour le B2B, LinkedIn et les communautés professionnelles/campus sont plus pertinents, avec des contenus orientés méthode, fiabilité et cas d'usage.

L'enjeu n'est pas d'être présent partout, mais d'être régulier là où les personas consomment déjà de l'information.

Effet attendu

Une présence sociale cohérente autour de la démo et de la vulgarisation doit produire trois effets marketing : augmenter la notoriété de VerifAI, améliorer la confiance envers l'outil et générer des visites qualifiées vers la page web de l'application.

En résumé, les réseaux sociaux deviennent un prolongement direct du produit : ils montrent, expliquent et donnent envie d'utiliser VerifAI dans des situations réelles.

4.6 Stratégie de collaborations et de publicités

Pour accélérer l'adoption de VerifAI, la stratégie de croissance combine des collaborations ciblées et des actions publicitaires légères. L'objectif n'est pas de maximiser le volume à court terme, mais d'obtenir une acquisition qualifiée, cohérente avec la promesse du produit : vérifier rapidement et comprendre clairement un résultat.

Collaborations prioritaires

Les collaborations sont pensées comme des relais de confiance. En phase initiale, VerifAI peut s'appuyer sur des partenaires proches des personas identifiés : associations étudiantes, médias campus, clubs de

journalisme, enseignants impliqués en éducation aux médias, ainsi que structures de communication locale.

Le principe est simple : proposer des démonstrations concrètes, des ateliers courts et des formats co-brandés. Ce type de partenariat favorise un bouche-à-oreille crédible et permet de tester le produit dans des contextes réels d’usage.

Logique B2C et logique B2B

En B2C, les collaborations doivent créer de la proximité et de la preuve d’utilité immédiate. Les actions les plus pertinentes sont les démonstrations en milieu étudiant, les contenus co-crésés avec des créateurs orientés vulgarisation et les challenges communautaires autour du réflexe “vérifier avant de partager”.

En B2B, la priorité est la crédibilité opérationnelle. Les partenariats visent des médias étudiants, des organismes de sensibilisation et des équipes communication qui peuvent intégrer VerifAI comme outil de pré-vérification dans leur flux de publication.

Publicité digitale à faible budget

La publicité payante intervient en complément des collaborations, avec un ciblage précis et des budgets maîtrisés. Les campagnes sont principalement orientées vers des contenus démo (vidéos courtes, captures commentées, cas concrets) afin de montrer la valeur en quelques secondes.

- sur Instagram/TikTok/X pour l’acquisition B2C ;
- sur LinkedIn pour la notoriété et la génération de contacts B2B ;
- avec redirection vers la page web pour tester l’outil immédiatement.

Le message publicitaire reste constant : “vérifier avant de partager”, avec un accent sur la simplicité d’usage et l’explicabilité du résultat.

Indicateurs de performance

L’évaluation des collaborations et publicités repose sur des indicateurs concrets : taux de clic, coût d’acquisition, taux d’essai de l’outil, part d’utilisateurs récurrents et retours qualitatifs des partenaires.

Cette mesure continue permet d’identifier les canaux les plus efficaces et d’ajuster rapidement les actions marketing sans perdre la cohérence stratégique.

Synthèse

La stratégie collaborations/publicités de VerifAI privilégie la confiance, la preuve d’usage et la régularité. Les collaborations apportent la crédibilité et l’ancrage terrain ; la publicité apporte l’amplification ciblée. Ensemble, ces deux leviers soutiennent une croissance progressive et réaliste, alignée avec les segments B2C et B2B.

Partie 5

Conclusion

Le Jalon 3 a confirmé la pertinence de l’architecture hybride (RAG & Llama 3) pour transformer VerifAI en un outil d’explication de la désinformation. Avec une précision globale de 72 % et un taux de détection des faits avérés de 95 %, les bases techniques et le positionnement marketing (B2C/B2B) sont désormais solidement établis.

Cependant, l’analyse de performance a révélé des zones de vulnérabilité, qui définissent nos objectifs pour le rendu final :

1. **Optimisation de la précision et robustesse sémantique** : L’objectif est d’atteindre une précision cible de 85 % en renforçant le modèle face aux théories du complot pseudo-scientifiques et aux absurdités formulées simplement, qui constituent actuellement nos principaux faux positifs.
2. **Implémentation du filtrage de fiabilité** : Intégrer un module de “vraisemblance de base” et un seuil de rejet automatique pour les scores de confiance inférieurs à 35 %. Cela permettra de substituer les erreurs par une réponse “Incertain”, garantissant la fiabilité du verdict pour l’utilisateur.
3. **Standardisation et rigueur de classification** : Affiner la logique du label “PARTIEL” pour qu’il ne s’applique qu’aux contenus dont la véracité est réellement mixte, éliminant ainsi les incohérences de notation observées durant les tests.
4. **Évaluation comparative et finale** : Conformément aux exigences du cours, le rendu final inclura une comparaison rigoureuse de la performance de VerifAI par rapport aux solutions concurrentes, tout en finalisant une interface utilisateur fluide et un code source prêt pour un déploiement commercial.

Nous devons également établir :

1. **Exploitation algorithmique des données temporelles** : Intégrer une véritable dimension temporelle dans le processus de détection (par exemple, analyser la chronologie de parution des articles ou l’évolution d’une rumeur dans le temps) pour dépasser la simple collecte quotidienne et améliorer concrètement les performances de classification.
2. **Définition du modèle d’affaires et de la tarification** : Conformément aux exigences du plan de cours, établir une stratégie de prix concurrentielle en analysant les coûts opérationnels et en choisissant un modèle de revenus (ex : freemium ou licence B2B) adapté aux besoins de nos personas.

En adressant ces points, VerifAI passera d’un prototype analytique performant à une solution mature, capable de s’imposer comme une solution courante contre la désinformation.

Références

- Kermani, Arshia, Veronica Perez-Rosas, et Vangelis Metsis. 2025. « A Systematic Evaluation of LLM Strategies for Mental Health Text Analysis : Fine-tuning vs. Prompt Engineering vs. RAG ». Prépublié mars 31. <https://doi.org/10.48550/arXiv.2503.24307>.
- Ovadia, Oded, Menachem Brief, Moshik Mishaeli, et Oren Elisha. 2024. « Fine-Tuning or Retrieval ? Comparing Knowledge Injection in LLMs ». Prépublié janvier 30. <https://doi.org/10.48550/arXiv.2312.05934>.
- Pornprasit, Chanathip, et Chakkrit Tantithamthavorn. 2024. « Fine-Tuning and Prompt Engineering for Large Language Models-based Code Review Automation ». Prépublié juin 17. <https://doi.org/10.48550/arXiv.2402.00905>.
- Shin, Jiho, Clark Tang, Tahmineh Mohati, Maleknaz Nayebi, Song Wang, et Hadi Hemmati. 2025. « Prompt Engineering or Fine-Tuning : An Empirical Assessment of LLMs for Code ». Prépublié février 19. <https://doi.org/10.48550/arXiv.2310.10508>.
- Vangibhurathachhi, Srinivasa Kalyan. 2025. « Adapting Large Language Models : A Comparative Study of Prompt Engineering and Fine-Tuning ». *International Journal of Emerging Research in Engineering and Technology* 6 (3) : 9-15. <https://doi.org/10.63282/3050-922X.IJERET-V6I3P102>.